



大数据分析技术

Chap. 8 流计算

王怡洋 副教授

大连海事大学 信息科学技术学院





内容提纲

- Chap. 8.1 流计算 概述
- Chap. 8.2 处理流程
- Chap. 8.3 应用
- Chap. 8.4 开源框架Storm
- Chap. 8.5 Storm编程实践

本PPT是基于如下教材的配套讲义：

《大数据技术原理与应用——概念、存储、处理、分析与应用》
(2017年2月第2版) 林子雨 编著，人民邮电出版社





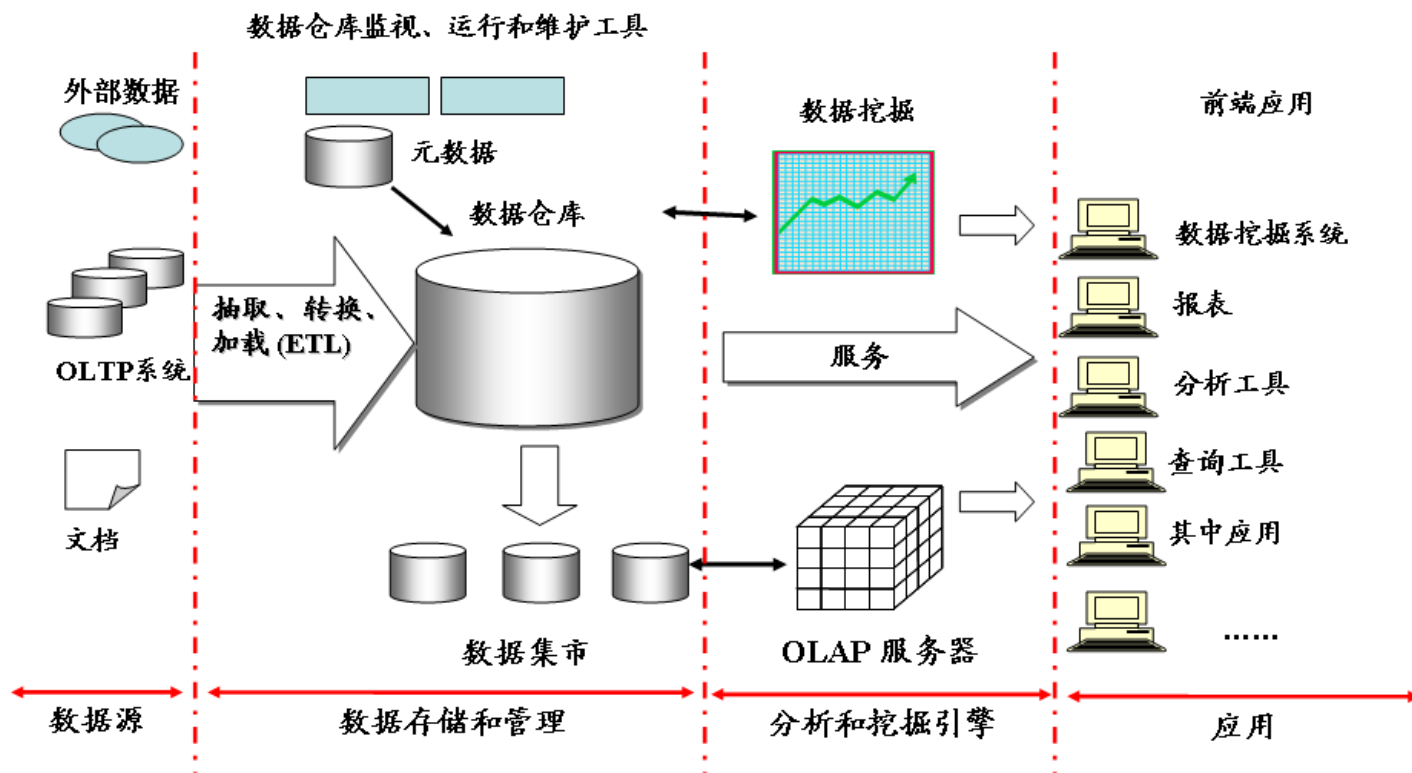
8.1 流计算概述

- 8.1.1 静态数据和流数据
- 8.1.2 批量计算和实时计算
- 8.1.3 流计算概念
- 8.1.4 流计算与Hadoop
- 8.1.5 流计算框架



8.1.1 静态数据和流数据

- 很多企业为了支持决策分析而构建的数据仓库系统，其中存放的大量历史数据就是静态数据。技术人员可以利用数据挖掘和OLAP（On-Line Analytical Processing）分析工具从静态数据中找到对企业有价值的信息





8.1.1 静态数据和流数据

- 近年来，在Web应用、网络监控、传感监测等领域，兴起了一种新的数据密集型应用——流数据，即数据以大量、快速、时变的流形式持续到达
- 实例：PM2.5检测、电子商务网站用户点击流
- 流数据具有如下特征：
 - 数据快速持续到达，潜在大小也许是无穷无尽的
 - 数据来源众多，格式复杂
 - 数据量大，但是不十分关注存储，一旦经过处理，要么被丢弃，要么被归档存储
 - 注重数据的整体价值，不过分关注个别数据
 - 数据顺序颠倒，或者不完整，系统无法控制将要处理的新到达的数据元素的顺序



8.1.2 批量计算和实时计算

- 对静态数据和流数据的处理，对应着两种截然不同的计算模式：批量计算和实时计算

- 批量计算：充裕时间处理静态数据，如Hadoop
- 流数据不适合采用批量计算，因为流数据不适合用传统的关系模型建模
- 流数据必须采用实时计算，响应时间为秒级
- 数据量少时，不是问题，但是，在大数据时代，数据格式复杂、来源众多、数据量巨大，对实时计算提出了很大的挑战。因此，针对流数据的实时计算——流计算，应运而生

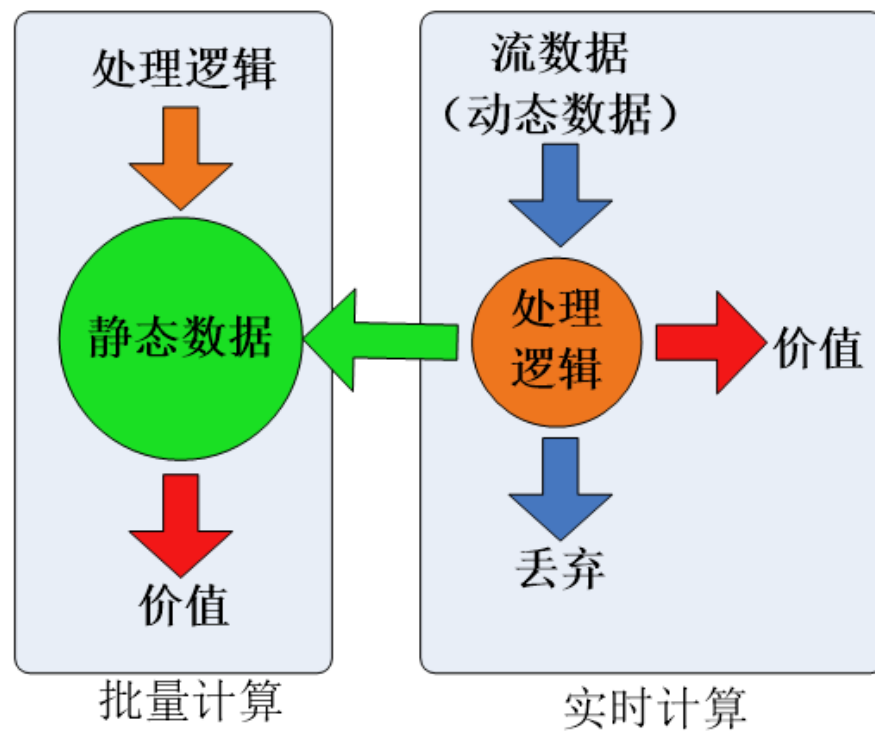


图8-2 数据的两种处理模型




8.2 流计算处理流程

- 8.2.1 概述
- 8.2.2 数据实时采集
- 8.2.3 数据实时计算
- 8.2.4 实时查询服务



8.2.1 数据处理流程

- 传统的数据处理流程，需要先采集数据并存储在关系数据库等数据管理系统中，之后由用户通过查询操作和数据管理系统进行交互



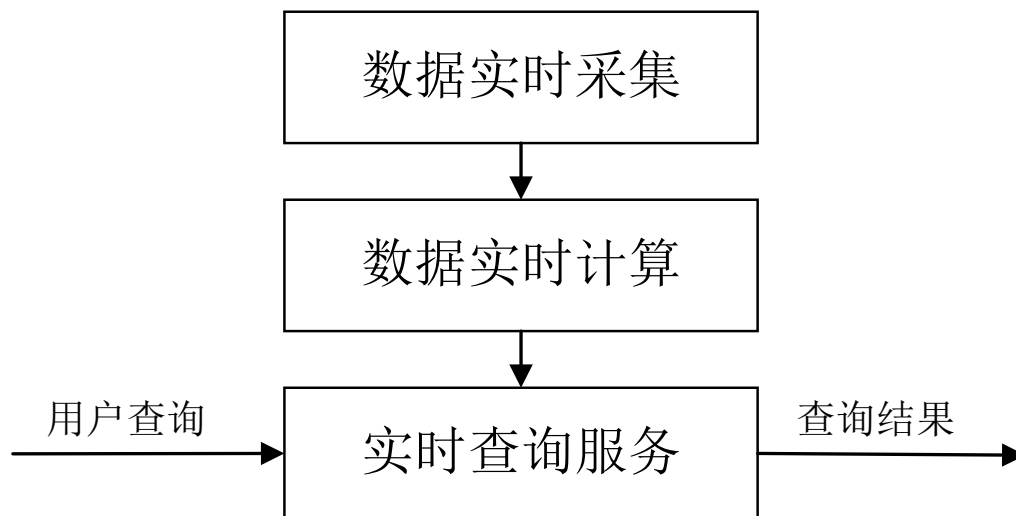
传统的数据处理流程示意图

- 传统的数据处理流程隐含了两个前提：
 - **存储的数据是旧的。**存储的静态数据是过去某一时刻的快照，这些数据在查询时可能已不具备时效性了
 - **需要用户主动发出查询来获取结果**



8.2.1 数据处理流程

- 流计算的处理流程一般包含三个阶段：数据实时采集、数据实时计算、实时查询服务

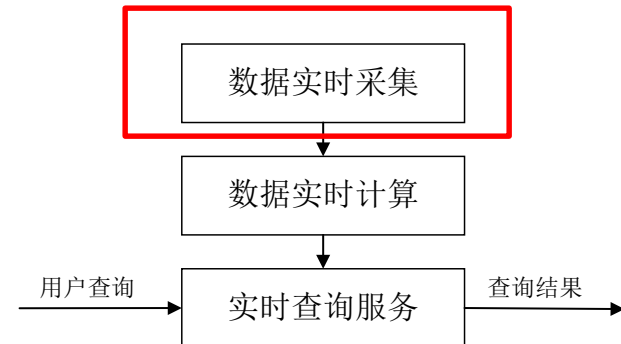


流计算处理流程示意图



8.2.2 数据实时采集


- 数据实时采集阶段通常采集多个数据源的海量数据，需要保证实时性、低延迟与稳定可靠
- 以日志数据为例，由于分布式集群的广泛应用，数据分散存储在不同的机器上，因此需要实时汇总来自不同机器上的日志数据
- 目前有许多互联网公司发布的开源分布式日志采集系统均可满足每秒数百MB的数据采集和传输需求，如：
 - Facebook的Scribe
 - LinkedIn的Kafka
 - 淘宝的Time Tunnel
 - 基于Hadoop的Chukwa和Flume





8.2.2 数据实时采集

- 数据采集系统的基本架构一般有以下三个部分：
 - Agent: 主动采集数据，并把数据推送到Collector部分
 - Collector: 接收多个Agent的数据，并实现有序、可靠、高性能的转发
 - Store: 存储Collector转发过来的数据（对于流计算不存储数据）

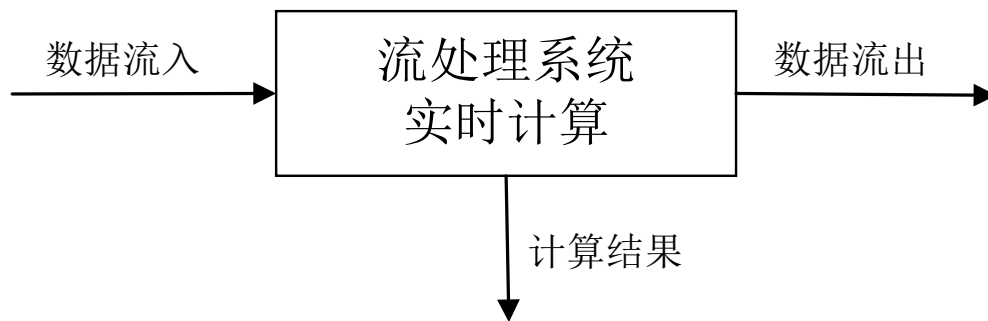


数据采集系统基本架构

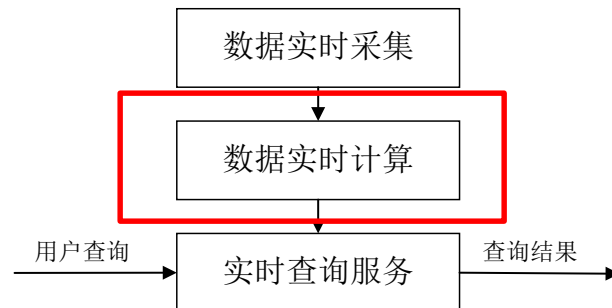


8.2.3 数据实时计算

- 数据实时计算阶段对采集的数据进行实时的分析和计算，并反馈实时结果
- 经流处理系统处理后的数据，可视情况进行存储，以便之后再进行分析计算。在时效性要求较高的场景中，处理之后的数据也可以直接丢弃



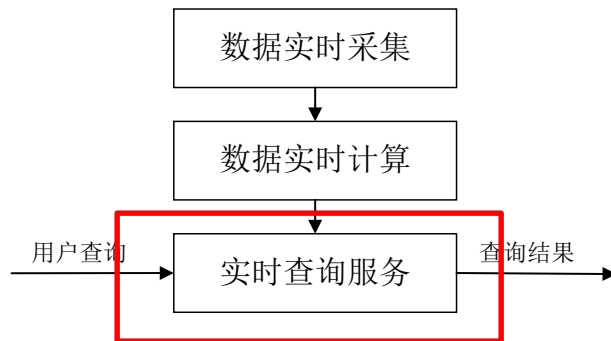
数据实时计算流程





8.2.3 实时查询服务

- 实时查询服务：经由流计算框架得出的结果可供用户进行实时查询、展示或储存
- 传统的数据处理流程，用户需要主动发出查询才能获得想要的结果。而在流处理流程中，实时查询服务可以不断更新结果，并将用户所需的结果实时推送给用户
- 虽然通过对传统的数据处理系统进行**定时**查询，也可以实现不断地更新结果和结果推送，但通过这样的方式获取的结果，仍然是根据过去某一时刻的数据得到的结果，与实时结果有着本质的区别





8.2.3 实时查询服务

- 可见，流处理系统与传统的数据处理系统有如下不同：
 - 流处理系统处理的是实时的数据，而传统的数据处理系统处理的是预先存储好的静态数据
 - 用户通过流处理系统获取的是实时结果，而通过传统的数据处理系统，获取的是过去某一时刻的结果
 - 流处理系统无需用户主动发出查询，实时查询服务可以主动将实时结果推送给用户



8.3 流计算的应用

- 流计算是针对流数据的实时计算，可以应用在多种场景中，如Web服务、机器翻译、广告投放、自然语言处理、气候模拟预测等
- 如百度、淘宝等大型网站中，每天都会产生大量流数据，包括用户的搜索内容、用户的浏览记录等数据。采用流计算进行实时数据分析，可以了解每个时刻的流量变化情况，甚至可以分析用户的实时浏览轨迹，从而进行实时个性化内容推荐
- 但是，并不是每个应用场景都需要用到流计算的。流计算适合于需要处理持续到达的流数据、对数据处理有较高实时性要求的场景



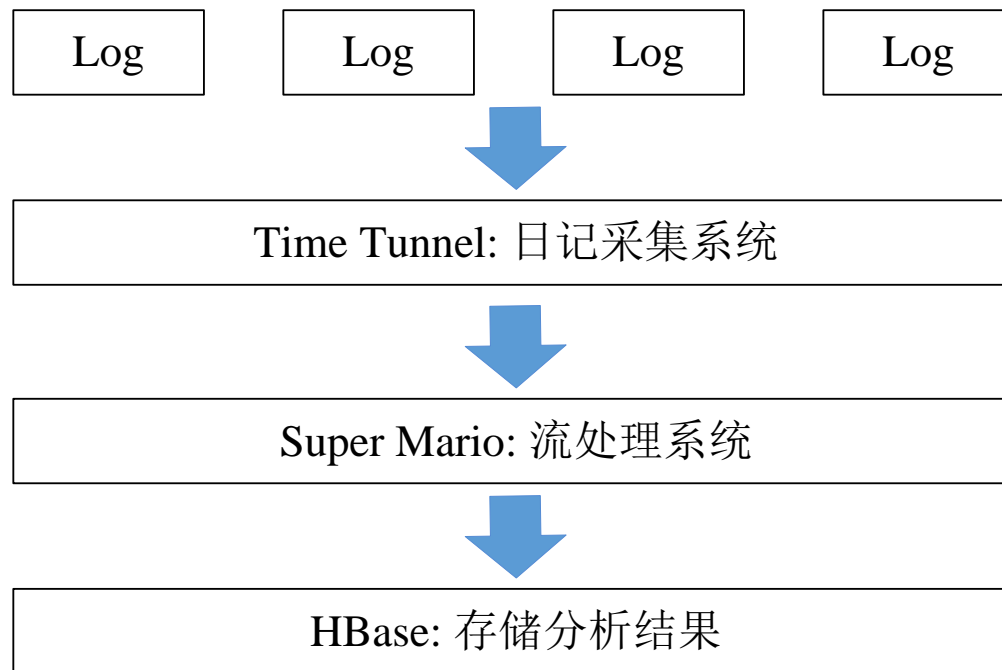
8.3.1 应用场景1: 实时分析

- 传统的业务分析一般采用分布式离线计算的方式，即将数据全部保存起来，然后每隔一定的时间进行离线分析来得到结果。但这样会导致一定的延时，难以保证结果的实时性
- 随着分析业务对实时性要求的提升，离线分析模式已经不适合用于流数据的分析，也不适用于要求实时响应的互联网应用场景
- 如淘宝网“双十一”、“双十二”的促销活动，商家需要根据广告效果来即时调整广告，这就需要对广告的受访情况进行分析。但以往采用分布式离线分析，需要几小时甚至一天的延时才能得到分析结果。而促销活动只持续一天，因此，隔天才能得到的分析结果便失去了价值
- 虽然分布式离线分析带来的小时级的分析延时可以满足大部分商家的需求，但随着实时性要求越来越高，如何实现秒级别的实时分析响应成为业务分析的一大挑战



8.3.1 应用场景1: 实时分析

- 针对流数据，“量子恒道”开发了海量数据实时流计算框架Super Mario。通过该框架，量子恒道可处理每天TB级的实时流数据，并且从用户发出请求到数据展示，整个延时控制在2-3秒内，达到了实时性的要求



Super Mario处理流程



8.3.1 应用场景2: 实时交通

- 流计算不仅为互联网带来改变，也能改变我们的生活
- 如提供导航路线，一般的导航路线并没有考虑实时的交通状况，即便在计算路线时有考虑交通状况，往往也只是使用了以往的交通状况数据。要达到根据实时交通状态进行导航的效果，就需要获取海量的实时交通数据并进行实时分析
- 借助于流计算的实时特性，不仅可以根椐交通情况制定路线，而且在行驶过程中，也可以根据交通情况的变化实时更新路线，始终为用户提供最佳的行驶路线



8.4 开源流计算框架Storm

- 8.4.1 Storm简介
- 8.4.2 Storm的特点
- 8.4.3 Storm设计思想
- 8.4.4 Storm框架设计



8.4 开源流计算框架Storm

- 以前只有政府机构和金融机构能够通过昂贵的定制系统来满足流数据实时分析计算需求
- 早期对于流计算的研究多数是基于对传统数据库处理的流式化，即实时数据库，很少研究流计算框架
- Yahoo! S4和Twitter Storm的开源，改变了这个情况
- 在流数据处理上比MapReduce更有优势
- 批处理系统关注吞吐率，流处理系统关注延时
- Yahoo! S4和Twitter Storm改变了开发实时应用的方式
 - 以前既要关注处理逻辑，还要解决实时数据获取、传输、存储
 - 现在可以快速低成本搭建起实时流处理系统



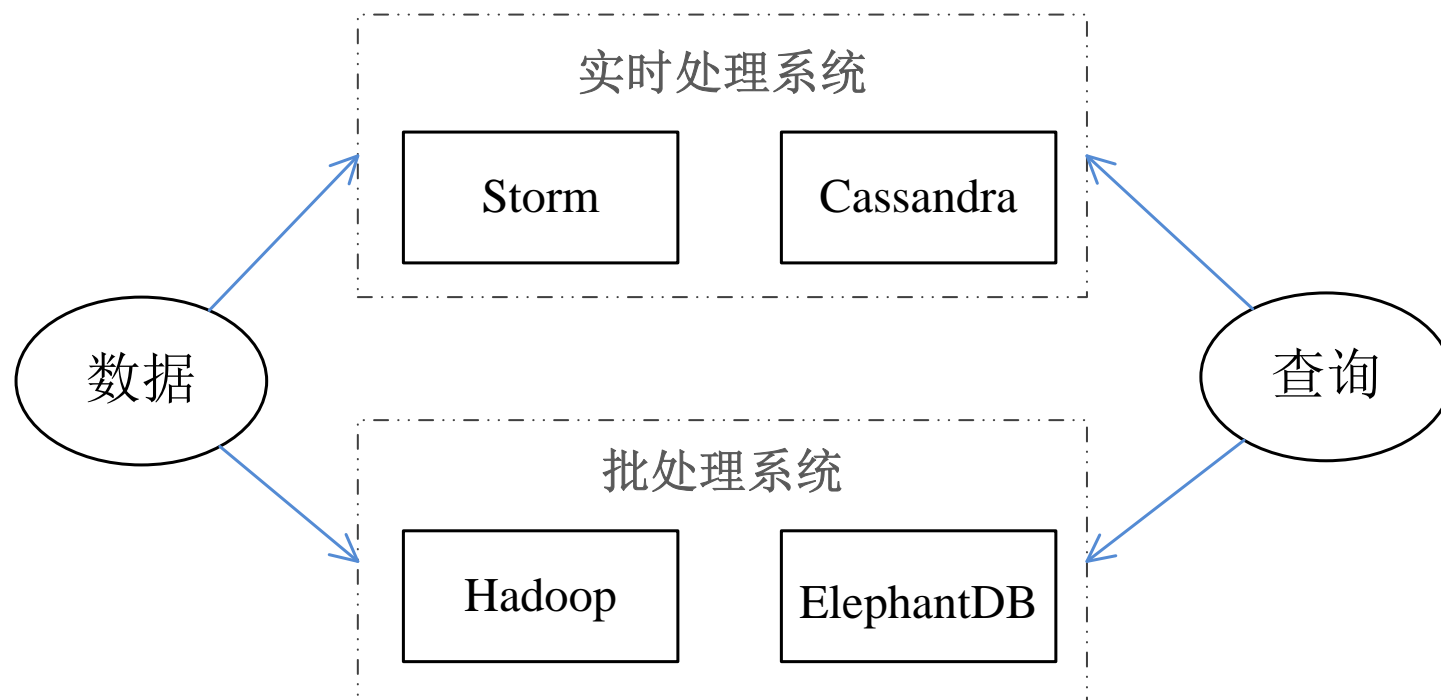
8.4.1 Storm简介

- Twitter Storm是一个免费、开源的分布式实时计算系统，Storm对于实时计算的意义类似于Hadoop对于批处理的意义，Storm可以简单、高效、可靠地处理流数据，并支持多种编程语言
- Storm框架可以方便地与数据库系统进行整合，从而开发出强大的实时计算系统



8.4.1 Storm简介

- Twitter是全球访问量最大的社交网站之一，Twitter开发Storm流处理框架也是为了应对其不断增长的流数据实时处理需求



Twitter的分层数据处理架构



8.4.2 Storm的特点

- Storm可用于许多领域中，如实时分析、在线机器学习、持续计算、远程RPC、数据提取加载转换等
- Storm具有以下主要特点：
 - 整合性：Storm可方便地与队列系统和数据库系统进行整合
 - 简易的API：Storm的API在使用上即简单又方便
 - 可扩展性：Storm的并行特性使其可以运行在分布式集群中
 - 容错性：Storm可自动进行故障节点的重启、任务的重新分配
 - 可靠的消息处理：Storm保证每个消息都能完整处理
 - 支持各种编程语言：Storm支持使用各种编程语言来定义任务
 - 快速部署：Storm可以快速进行部署和使用
 - 免费、开源：Storm是一款开源框架，可以免费使用




8.4.3 Storm设计思想

- Storm主要术语包括Streams、Spouts、Bolts、Topology和Stream Groupings
- Streams:** Storm将流数据Stream描述成一个无限的Tuple序列，这些Tuple序列会以分布式的方式并行地创建和处理

Streams

无界的Tuple序列



- 每个tuple是一堆值，每个值有一个名字，并且每个值可以是任何类型
- Tuple本来应该是一个Key-Value的Map，由于各个组件间传递的tuple的字段名称已经事先定义好了，所以Tuple只需要按序填入各个Value，所以就是一个Value List（值列表）

Field1

Field2

Field3

Field4




8.4.3 Storm设计思想

- **Spout:** Storm认为每个Stream都有一个源头，并把这个源头抽象为Spout
- 通常Spout会从外部数据源（队列、数据库等）读取数据，然后封装成Tuple形式，发送到Stream中。Spout是一个主动的角色，在接口内部有个nextTuple函数，Storm框架会不停的调用该函数

Spouts

Streams的来源



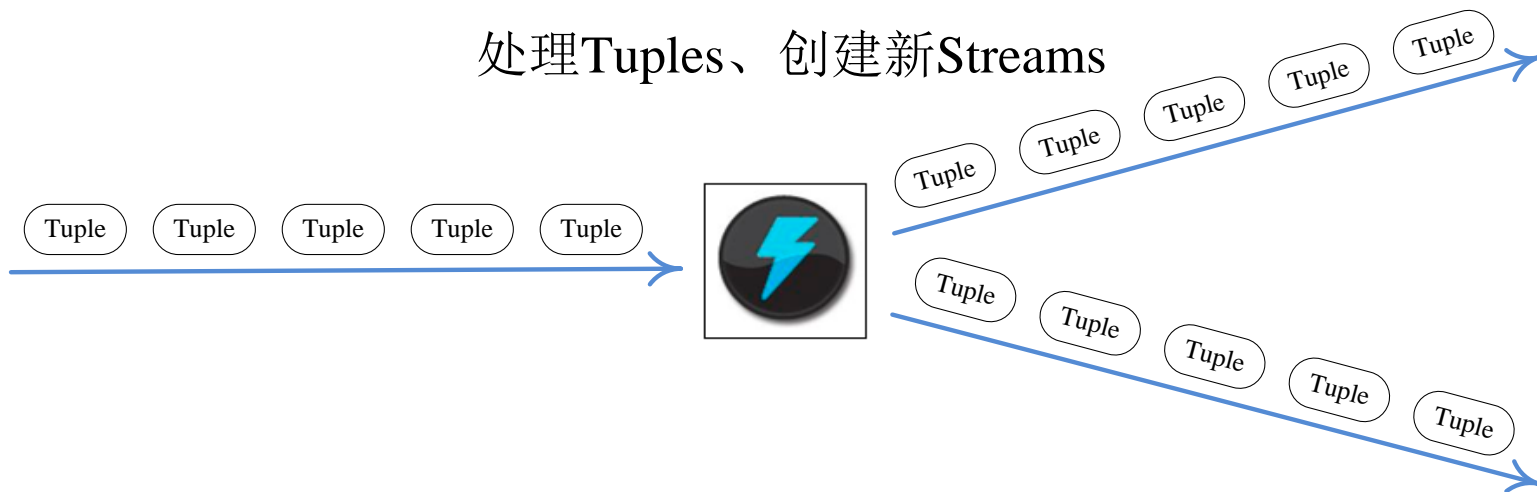


8.4.3 Storm设计思想

- **Bolt**: Storm将Streams的状态转换过程抽象为Bolt。Bolt即可以处理Tuple，也可以将处理后的Tuple作为新的Streams发送给其他Bolt
- Bolt可以执行过滤、函数操作、Join、操作数据库等任何操作
- Bolt是一个被动的角色，其接口中有一个execute(Tuple input)方法，在接收到消息之后会调用此函数，用户可以在此方法中执行自己的处理逻辑

Bolts

处理Tuples、创建新Streams






8.4.3 Storm设计思想

- **Topology:** Storm将Spouts和Bolts组成的网络抽象成Topology，它可以被提交到Storm集群执行。Topology可视为流转换图，图中节点是一个Spout或Bolt，边则表示Bolt订阅了哪个Stream。当Spout或者Bolt发送元组时，它会把元组发送到每个订阅了该Stream的Bolt上进行处理
- Topology里面的每个处理组件（Spout或Bolt）都包含处理逻辑，而组件之间的连接则表示数据流动的方向
- Topology里面的每一个组件都是并行运行的

- 在Topology里面可以指定每个组件的并行度，Storm会在集群里面分配那么多的线程来同时计算

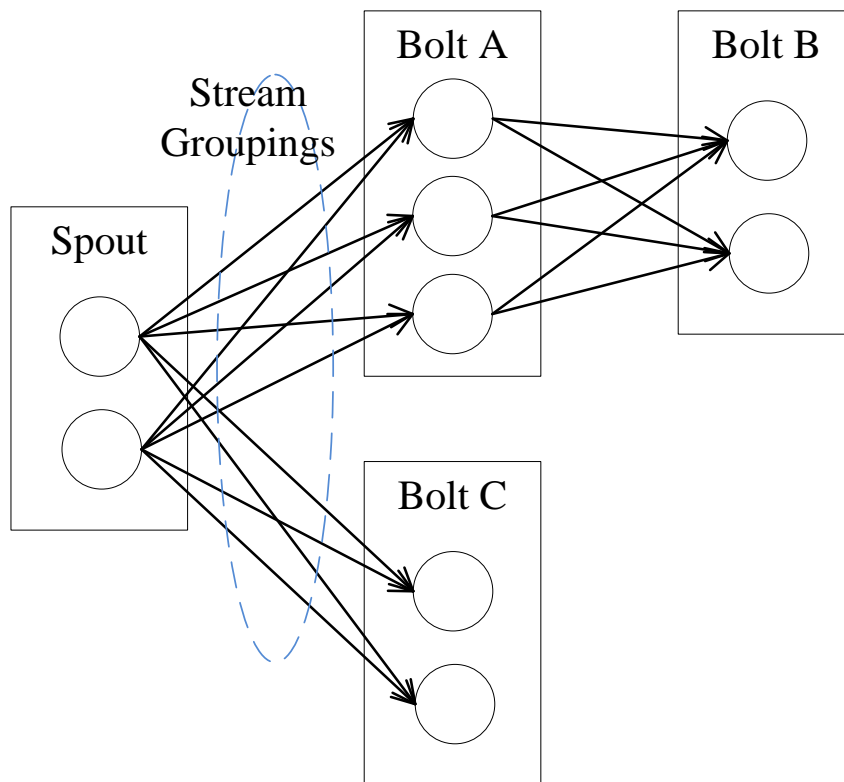
- 在Topology的具体实现上，Storm中的Topology定义仅仅是一些Thrift结构体（二进制高性能的通信中间件），支持各种编程语言进行定义





8.4.3 Storm设计思想

- **Stream Groupings:** Storm中的Stream Groupings用于告知Topology如何在两个组件间（如Spout和Bolt之间，或者不同的Bolt之间）进行Tuple的传送。每一个Spout和Bolt都可以有多个分布式任务，一个任务在什么时候、以什么方式发送Tuple就是由Stream Groupings来决定的





8.4.3 Storm设计思想

目前，Storm中的Stream Groupings有如下几种方式：

- (1) ShuffleGrouping：随机分组，随机分发Stream中的Tuple，保证每个Bolt的Task接收Tuple数量大致一致
- (2) FieldsGrouping：按照字段分组，保证相同字段的Tuple分配到同一个Task中
- (3) AllGrouping：广播发送，每一个Task都会收到所有的Tuple
- (4) GlobalGrouping：全局分组，所有的Tuple都发送到同一个Task中
- (5) NonGrouping：不分组，和ShuffleGrouping类似，当前Task的执行会和它的被订阅者在同一个线程中执行
- (6) DirectGrouping：直接分组，直接指定由某个Task来执行Tuple的处理



8.4.4 Storm框架设计

- Storm运行任务的方式与Hadoop类似：Hadoop运行的是MapReduce作业，而Storm运行的是“Topology”
- 但两者的任务大不相同，主要的不同是：MapReduce作业最终会完成计算并结束运行，而Topology将持续处理消息（直到人为终止）

Storm和Hadoop架构组件功能对应关系

	Hadoop	Storm
应用名称	Job	Topology
系统角色	JobTracker	Nimbus
	TaskTracker	Supervisor
组件接口	Map/Reduce	Spout/Bolt



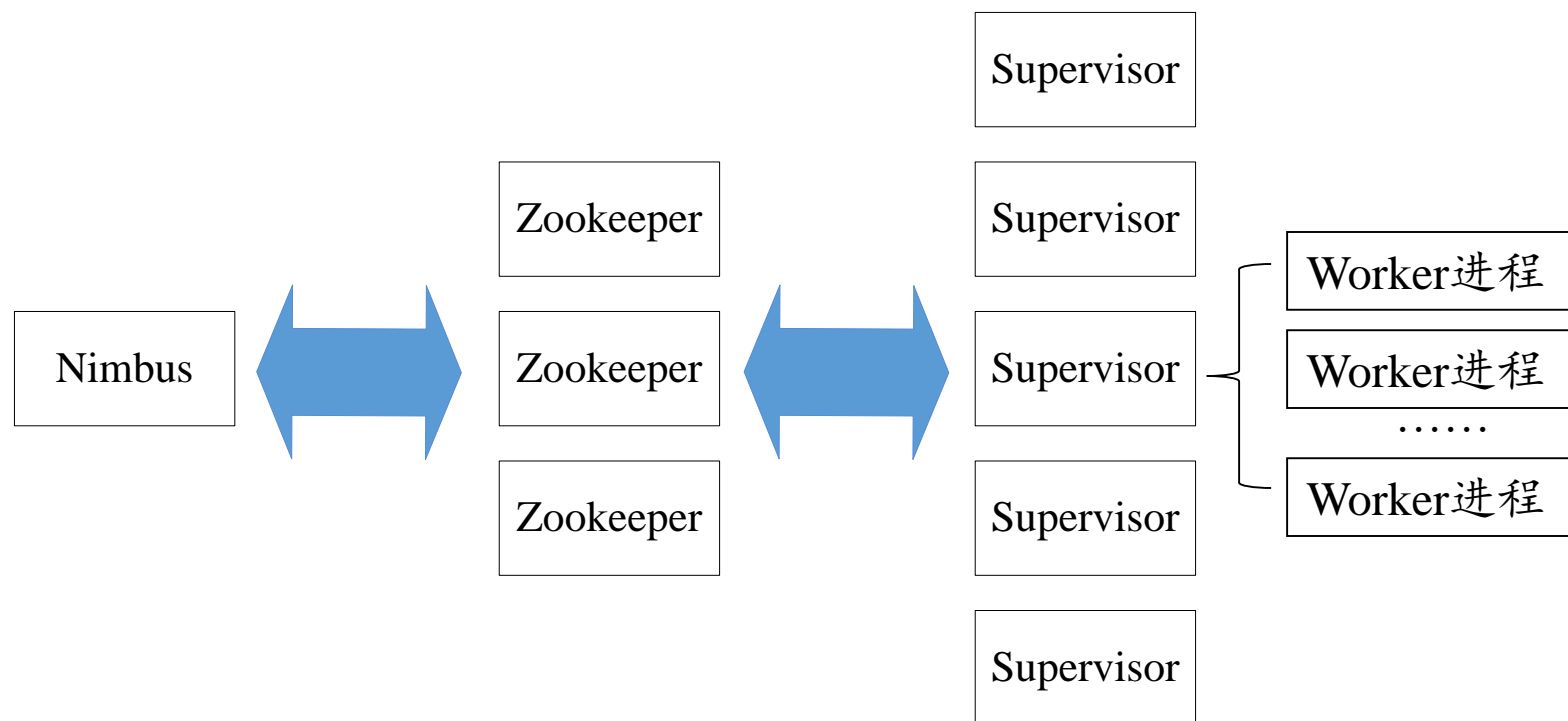
8.4.4 Storm框架设计

- Storm集群采用“Master—Worker”的节点方式：
 - Master节点运行名为“Nimbus”的后台程序（类似Hadoop中的“JobTracker”），负责在集群范围内分发代码、为Worker分配任务和监测故障
 - Worker节点运行名为“Supervisor”的后台程序，负责监听分配给它所在机器的工作，即根据Nimbus分配的任务来决定启动或停止Worker进程，一个Worker节点上同时运行若干个Worker进程



8.4.4 Storm框架设计

- Storm使用Zookeeper来作为分布式协调组件，负责Nimbus和多个Supervisor之间的所有协调工作。借助于Zookeeper，若Nimbus进程或Supervisor进程意外终止，重启时也能读取、恢复之前的状态并继续工作，使得Storm极其稳定

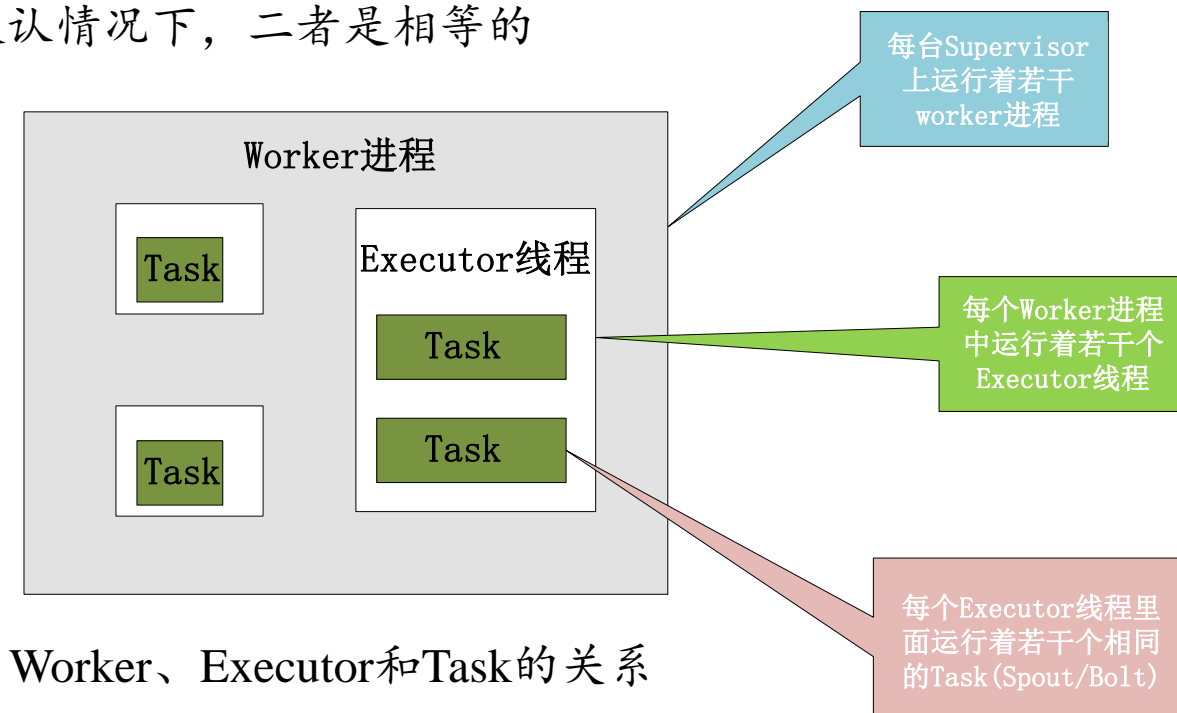


Storm集群架构示意图



8.4.4 Storm框架设计

- (1) worker: 每个worker进程都属于一个特定的Topology，每个Supervisor节点的worker可以有多个，每个worker对Topology中的每个组件（Spout或 Bolt）运行一个或者多个executor线程来提供task的运行服务
- (2) executor: executor是产生于worker进程内部的线程，会执行同一个组件的一个或者多个task。
- (3) task: 实际的数据处理由task完成，在Topology的生命周期中，每个组件的task数目是不会发生变化的，而executor的数目却不一定。executor数目小于等于task的数目，默认情况下，二者是相等的

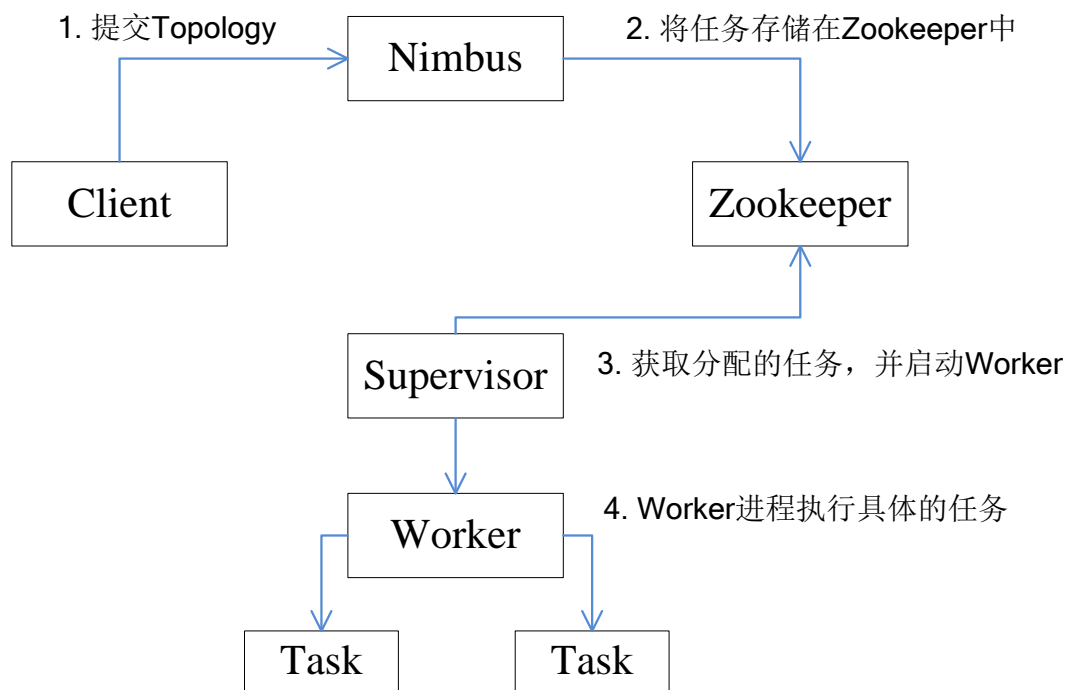




8.4.4 Storm框架设计

• 基于这样的架构设计，Storm的工作流程如下图所示：

- 所有Topology任务的提交必须在Storm客户端节点上进行，提交后，由Nimbus节点分配给其他Supervisor节点进行处理
- Nimbus节点首先将提交的Topology进行分片，分成一个个Task，分配给相应的Supervisor，并将Task和Supervisor相关的信息提交到Zookeeper集群上
- Supervisor会去Zookeeper集群上认领自己的Task，通知自己的Worker进程进行Task的处理
- 说明：在提交了一个Topology之后，Storm就会创建Spout/Bolt实例并进行序列化。之后，将序列化的组件发送给所有的任务所在的机器(即Supervisor节点)，在每一个任务上反序列化组件



Storm工作流程示意图



8.5 Storm编程实践

8.5.1 编写Storm程序

8.5.2 安装Storm的基本过程

8.5.3 运行Storm程序

Storm上机实践详细过程，请参考《流计算学习指南》

访问地址：<http://dblab.xmu.edu.cn/blog/767/>



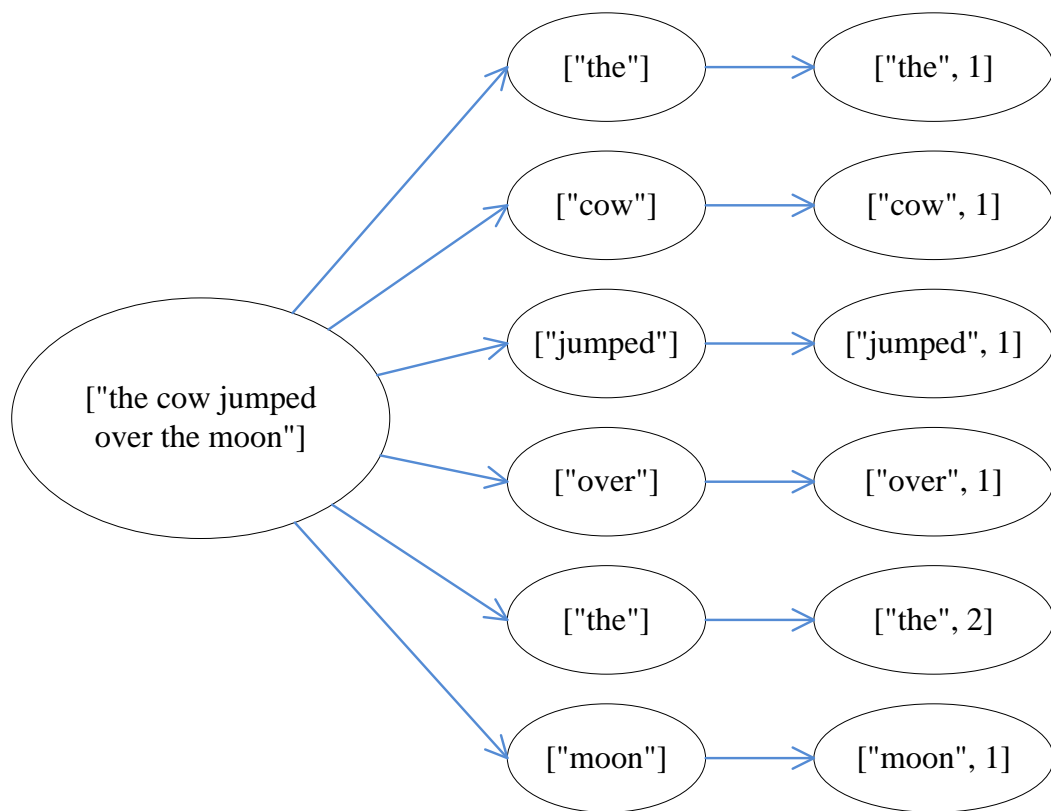
8.5.1 编写Storm程序

程序任务：单词统计

- 基于Storm的单词统计在形式上与基于MapReduce的单词统计是类似的，MapReduce使用的是Map和Reduce的抽象，而Storm使用的是Spout和Bolt的抽象
- Storm进行单词统计的整个流程：
 - 从Spout中发送Stream（每个英文句子为一个Tuple）
 - 用于分割单词的Bolt将接收的句子分解为独立的单词，将单词作为Tuple的字段名发送出去
 - 用于计数的Bolt接收表示单词的Tuple，并对其进行统计
 - 输出每个单词以及单词出现过的次数



8.5.1 编写Storm程序



一个句子经Storm的单词统计得出的结果



8.5.1 编写Storm程序

Storm的编程模型非常简单，如下代码即定义了整个单词统计Topology的整体逻辑

```
import org.apache.storm.Config;
Import .....
public class WordCountTopology {
    public static class RandomSentenceSpout extends BaseRichSpout {
        .....
    }
    public static class SplitSentence extends ShellBolt implements IRichBolt {
        .....
    }
    public static class WordCount extends BaseBasicBolt {
        .....
    }
    public static void main(String[] args) throws Exception {
        TopologyBuilder builder = new TopologyBuilder();
        builder.setSpout("sentences", new RandomSentenceSpout(), 5);
        builder.setBolt("split", new SplitSentence(), 8).shuffleGrouping("sentences");
        builder.setBolt("count", new WordCount(), 12).fieldsGrouping("split", new Fields("word"));
        .....
    }
}
```




8.5.1 编写Storm程序

- `main()`函数中的处理逻辑

```
// 创建一个Topology builder
TopologyBuilder builder = new TopologyBuilder();
// 使用builder.setSpout()方法对Spout数据源进行定义
builder.setSpout("sentences", new RandomSentenceSpout(), 5);
// 使用builder.setBolt()定义Bolt处理任务
builder.setBolt("split", new SplitSentence(), 8)
        .shuffleGrouping("sentences");
// Groupings()系列方法定义了Tuple发送方式
builder.setBolt("count", new WordCount(), 12)
        .fieldsGrouping("split", new Fields("word"));
```

Topology中仅定义了整体的计算逻辑，还需要定义具体的处理函数。具体的处理函数可以使用任一编程语言来定义，甚至也可以结合多种编程语言来实现



8.5.1 编写Storm程序

•RandomSentenceSpout类

备注：为简单起见，RandomSentenceSpout省略了类中的一些方法

```
public class RandomSentenceSpout extends BaseRichSpout {  
    SpoutOutputCollector _collector;  
    Random _rand;  
    @Override  
    public void nextTuple() {  
        Utils.sleep(100);  
        String[] sentences = new String[]{ "the cow jumped over the moon", "an apple a day keeps the doctor away",  
            "four score and seven years ago", "snow white and the seven dwarfs", "i am at two with nature" };  
        String sentence = sentences[_rand.nextInt(sentences.length)];  
        _collector.emit(new Values(sentence));  
    }  
  
    @Override  
    public void declareOutputFields(OutputFieldsDeclarer declarer) {  
        declarer.declare(new Fields("sentences"));  
    }  
}
```



8.5.1 编写Storm程序

•SplitSentence类

- 如SplitSentence()方法虽然是通过Java语言定义的，但具体的操作可通过Python脚本来完成
- Topology里面的每个组件必须定义它要发射的Tuple的每个字段

```
public static class SplitSentence extends ShellBolt implements IRichBolt {  
    public SplitSentence() {  
        // 单词分割的具体实现由Python脚本实现  
        super("python", "splitsentence.py");  
    }  
    public void declareOutputFields(OutputFieldsDeclarer declarer) {  
        declarer.declare(new Fields("word"));  
    }  
}
```



8.5.1 编写Storm程序

• splitsentence.py

- Python脚本splitsentence.py定义了一个简单的单词分割方法，即通过空格来分割单词。分割后的单词通过emit()方法以Tuple的形式发送给订阅了该Stream的Bolt进行接收和处理

```
# 简单的单词分割实现，以空格作为分割点
import storm
class SplitSentenceBolt(storm.BasicBolt):
    def process(self, tup):
        words = tup.values[0].split(" ")
        for word in words:
            storm.emit([word])
SplitSentenceBolt().run()
```



8.5.1 编写Storm程序

• WordCount类

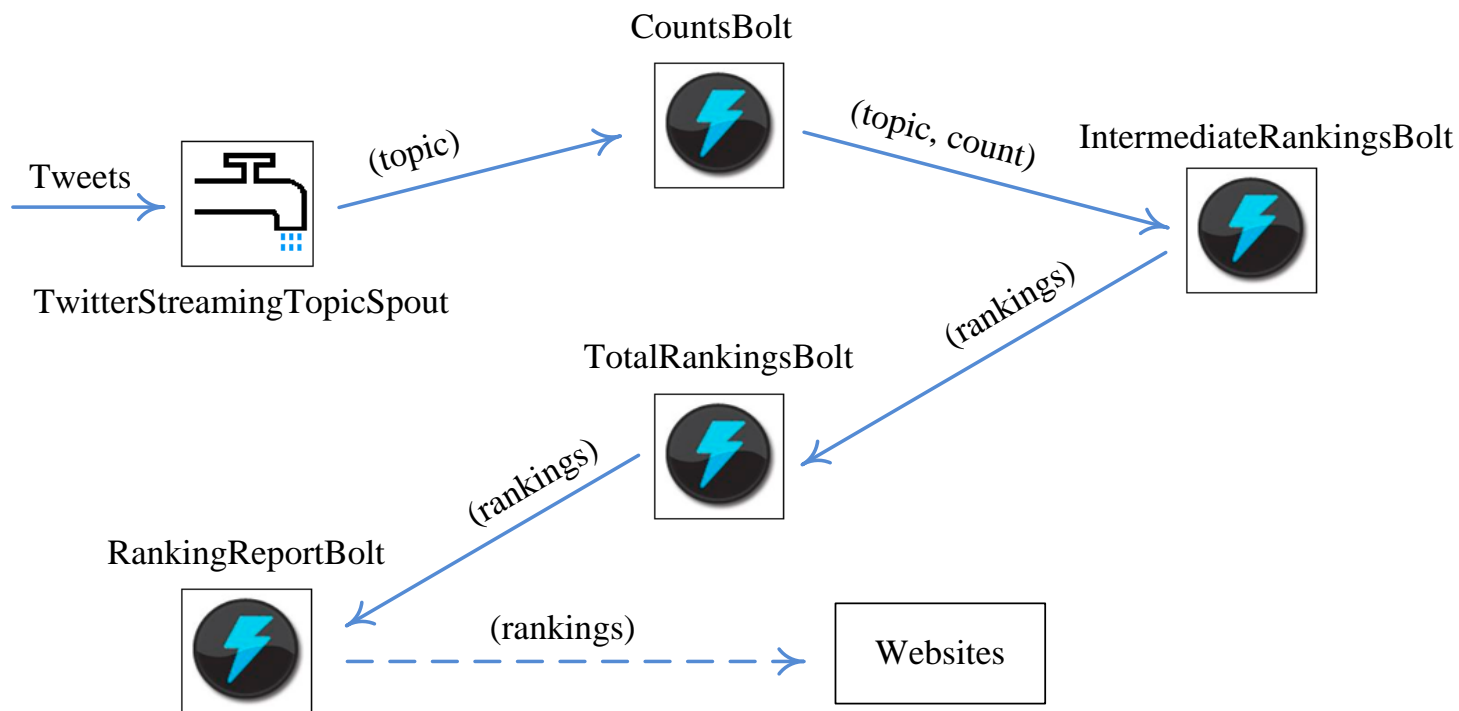
- 单词统计的具体逻辑：首先判断单词是否统计过，若未统计过，需先将count值置为0。若单词已统计过，则每出现一次该单词，count值就加1

```
// 对单词进行计数
public static class WordCount extends BaseBasicBolt {
    Map<String, Integer> counts = new HashMap<String, Integer>();
    @Override
    public void execute(Tuple tuple, BasicOutputCollector collector) {
        String word = tuple.getString(0);
        Integer count = counts.get(word);
        if (count == null)
            count = 0;
        count++;
        counts.put(word, count);
        collector.emit(new Values(word, count));
    }
    @Override
    public void declareOutputFields(OutputFieldsDeclarer declarer) {
        declarer.declare(new Fields("word", "count"));
    }
}
```




8.5.1 编写Storm程序

- 上述虽然是一个简单的单词统计，但对其进行扩展，便可应用到许多场景中，如微博中的实时热门话题。Twitter也正是使用了Storm框架实现了实时热门话题



Twitter实时热门话题处理流程示意图



8.5.2 安装Storm的基本过程

本实例中Storm具体运行环境如下：

- CentOS 6.4
- Storm 0.9.6
- Java JDK 1.7
- ZooKeeper 3.4.6
- Python 2.6

备注：CentOS中已默认安装了Python 2.6，我们还需要安装JDK环境以及分布式应用程序协调服务 Zookeeper

安装Storm的基本过程如下：

- 第一步：安装Java环境
- 第二步：安装 Zookeeper
- 第三步：安装Storm（单机）
- 第四步：关闭Storm

Storm上机实践详细过程，请参考《第八章 流计算学习指南》

<http://dblab.xmu.edu.cn/blog/767/>



8.5.2 安装Storm的基本过程

第一步：安装Java环境

• Storm 运行需要 Java 环境，可选择 Oracle 的 JDK，或是 OpenJDK，现在一般 Linux 系统默认安装的基本是 OpenJDK，如 CentOS 6.4 就默认安装了 OpenJDK 1.7。但需要注意的是，CentOS 6.4 中默认安装的只是 Java JRE，而不是 JDK，为了开发方便，我们还是需要通过 yum 进行安装 JDK

```
$ sudo yum install java-1.7.0-openjdk java-1.7.0-openjdk-devel
```

• 接着需要配置一下 JAVA_HOME 环境变量，为方便，可以在 ~/.bashrc 中进行设置



```
hadoop@dblab:~  
窗口菜单 编辑(E) 查看(V) 搜索(S) 终端(T) 帮助(H)  
# .bashrc  
  
# Source global definitions  
if [ -f /etc/bashrc ]; then  
    . /etc/bashrc  
fi  
  
# User specific aliases and functions  
export JAVA_HOME=/usr/lib/jvm/java-1.7.0-openjdk
```

廈門大學
數據庫實驗室



8.5.2 安装Storm的基本过程

第二步：安装Zookeeper

到官网下载Zookeeper，比如下载“zookeeper-3.4.6.tar.gz”

下载后执行如下命令进行安装 zookeeper（将命令中 3.4.6 改为你下载的版本）：

```
$ sudo tar -zxf ~/下载/zookeeper-3.4.6.tar.gz -C /usr/local  
$ cd /usr/local  
$ sudo mv zookeeper-* zookeeper #修改目录名称方便使用  
$ sudo chown -R hadoop:hadoop ./zookeeper #此处的hadoop为你的用户名
```

chown命令让hadoop用户拥有zookeeper目录下的所有文件的权限



8.5.2 安装Storm的基本过程

第二步：安装Zookeeper（续）

接着执行如下命令进行zookeeper配置：

```
$ cd /usr/local/zookeeper  
$ mkdir tmp  
$ cp ./conf/zoo_sample.cfg ./conf/zoo.cfg  
$ vim ./conf/zoo.cfg
```

进入zoo.cfg文件编辑状态后，将当中的 dataDir=/tmp/zookeeper 更改为 dataDir=/usr/local/zookeeper/tmp 。接着执行：

```
$ ./bin/zkServer.sh start
```




8.5.2 安装Storm的基本过程

第三步：安装Storm（单机）

到官网下载Storm，比如Storm0.9.6

下载后执行如下命令进行安装Storm：

```
$ sudo tar -zxf ~/下载/apache-storm-0.9.6.tar.gz -C /usr/local
$ cd /usr/local
$ sudo mv apache-storm-0.9.6 storm
$ sudo chown -R hadoop:hadoop ./storm # 此处的hadoop为你的用户名
```

接着执行如下命令进行Storm配置：

```
$ cd /usr/local/storm
$ vim ./conf/storm.yaml
```

备注：storm的运行有两种模式：本地模式和分布式模式。在本地模式中，storm用一个进程里面的线程来模拟所有的spout和bolt。本地模式对开发和测试来说比较有用。在分布式模式下，storm由一堆机器组成。当提交topology给master的时候，master负责分发代码并且负责给topology分配工作进程。如果一个工作进程挂掉了，master节点会把它重新分配到其它节点。



8.5.2 安装Storm的基本过程

第三步：安装Storm（单机）（续）

修改其中的 storm.zookeeper.servers 和 nimbus.host 两个配置项，即取消掉注释且都修改值为 127.0.0.1（我们只需要在单机上运行），如下图所示。



```
hadoop@dblab:/usr/local/storm
文件(F) 编辑(E) 查看(V) 搜索(S) 终端(T) 帮助(H)

##### These MUST be filled in for a storm configuration
storm.zookeeper.servers:
    - "127.0.0.1"
    # - "server2"
#
#
nimbus.host: "127.0.0.1"
#
#
# ##### These may optionally be filled in:
#
#
```

然后就可以启动 Storm 了。执行如下命令启动 nimbus 后台进程：

```
$ ./bin/storm nimbus
```



8.5.2 安装Storm的基本过程

第三步：安装Storm（单机）（续）

启动 nimbus 后，终端被该进程占用了，不能再继续执行其他命令了。因此我们需要另外开启一个终端，然后执行如下命令启动 supervisor 后台进程：

```
$ # 需要另外开启一个终端  
$ /usr/local/storm/bin/storm supervisor
```

同样的，启动 supervisor 后，我们还需要开启另外的终端才能执行其他命令。另外，我们可以使用 jps 命令 检查是否成功启动，若成功启动会显示 nimbus、supervisor、QuorumPeerMain（QuorumPeerMain 是 zookeeper 的后台进程，若显示 config_value 表明 nimbus 或 supervisor 还在启动中），如下图所示。



```
hadoop@dblab:~  
文件(F) 编辑(E) 查看(V) 搜索(S) 终端(T) 帮助(H)  
[hadoop@dblab ~]$ jps  
3182 supervisor  
2664 QuorumPeerMain  
2993 nimbus  
3230 Jps  
[hadoop@dblab ~]$
```



8.5.2 安装Storm的基本过程

第四步：关闭Storm

之前启动的 nimbus 和 supervisor 占用了两个终端窗口，切换到这两个终端窗口，按键盘的 Ctrl+C 可以终止进程，终止后，也就相当于关闭了 Storm

。



8.5.3 运行Storm实例

- 运行Storm计算任务，就是提交Topology
- 运行一个Topology是很简单的。首先，把所有的代码以及所依赖的jar打进一个jar包。然后运行类似下面的这个命令

```
storm jar all-your-code.jar backtype.storm.MyTopology  
arg1 arg2
```

- storm jar 负责连接到nimbus并且上传jar文件



8.5.3 运行Storm实例

Storm中自带了一些例子，我们可以执行一下 WordCount 例子来感受一下 Storm 的执行流程。执行如下命令：

```
$ /usr/local/storm/bin/storm jar /usr/local/storm/examples/storm-starter/storm-starter-topologies-0.9.6.jar storm.starter.WordCountTopology
```

该程序是不断地取如下英文句子中的一句作为数据源，然后发送给 bolt 来统计单词出现的次数。

```
{  
"the cow jumped over the moon",  
"an apple a day keeps the doctor away",  
"four score and seven years ago",  
"snow white and the seven dwarfs",  
"i am at two with nature"  
}
```